



Politechnika Warszawska

**Wydział Matematyki
i Nauk Informatycznych**

Wstęp do algorytmów ewolucyjnych

Porównanie działania algorytmu MO-CMA-ES z algorytmem EGO

Projekt nr 4

Zespół:

Igor Januszkiewicz

Filip Filipkowski

Sandra Adamiec

Warszawa, kwiecień 2026

1 Opis problemu i jego sposobu rozwiązania

Celem projektu jest przeprowadzenie analizy porównawczej dwóch algorytmów optymalizacji: **CMA-ES** (Covariance Matrix Adaptation Evolution Strategy) oraz **EGO** (Efficient Global Optimization), w wersjach wielokryterialnych, gdzie poszukiwany jest zbiór rozwiązań optymalnych w sensie Pareto.

1.1 Charakterystyka algorytmów

- **MO-CMA-ES**: Jest to wielokryterialne rozszerzenie jednego z najskuteczniejszych algorytmów optymalizacji ciągłej (CMA-ES). Algorytm ten wykorzystuje mechanizm adaptacji macierzy kowariancji do modelowania struktury lokalnej funkcji celu, co pozwala na efektywne poruszanie się w trudnych, źle uwarunkowanych przestrzeniach przeszukiwań. W wersji wielokryterialnej często bazuje na mierze hiperobjętości (Hypervolume) lub kryterium niezdominowania (Non-dominated sorting).
- **EGO**: Reprezentuje klasę algorytmów optymalizacji bayesowskiej (Surrogate-based Optimization). EGO buduje model zastępczy (zazwyczaj proces gaussowski/kriging) funkcji celu, a następnie wykorzystuje funkcję akwizycji (np. Expected Improvement), aby wyznaczyć kolejne punkty do ewaluacji. Jest to algorytm dedykowany problemom kosztownym obliczeniowo, gdzie liczba ewaluacji rzeczywistej funkcji jest mocno ograniczona.

1.2 Metoda rozwiązania

Problem zostanie rozwiązany poprzez implementację obu algorytmów (lub wykorzystanie ich sprawdzonych implementacji bibliotecznych) i poddanie ich testom na ujednoliconym zestawie funkcji testowych. Głównym wyzwaniem jest porównanie algorytmu opartego na populacji (MO-CMA-ES) z algorytmem opartym na modelu (EGO) w kontekście różnego budżetu ewaluacji oraz wymiarowości problemu.

2 Planowane eksperymenty numeryczne

Eksperymenty zostaną przeprowadzone przy użyciu benchmarku **BBOB-BIOBJ** w ramach frameworku **COCO** (Comparing Continuous Optimizers).

2.1 Metodologia badań

- **Zbiór funkcji testowych**: Wykorzystanych zostanie 55 funkcji testowych z zestawu BBOB-BIOBJ, obejmujących problemy o różnej charakterystyce: separowalne, nieseparowalne, o różnym stopniu uwarunkowania i strukturze frontu Pareto.
- **Wymiarowość (D)**: Eksperymenty zostaną przeprowadzone dla wymiarów $D \in \{2, 3, 5, 10\}$.
- **Budżet obliczeniowy**: Z uwagi na specyfikę algorytmu EGO, porównanie obejmie tzw. "mały budżet" ($10D$ do $100D$ ewaluacji) oraz "duży budżet" ($1000D+$) dla MO-CMA-ES, aby sprawdzić, w którym punkcie algorytm ewolucyjny zaczyna przewyższać podejście modelowe.
- **Metryki oceny**:

- **ERT (Expected Running Time):** Czas/liczba ewaluacji potrzebna do osiągnięcia zadanego poziomu wskaźnika Hypervolume.
- **Data Profiles:** Wykresy pokazujące frakcję rozwiązanych problemów w funkcji budżetu.
- **Wykresy zdominowania:** Bezpośrednie porównanie jakości frontów Pareto uzyskanych przez oba algorytmy.

3 Wybór technologii

Projekt zostanie zrealizowany przy użyciu następujących technologii:

- **Język programowania: Python 3.x** – ze względu na bogatą dostępność bibliotek do optymalizacji oraz natywne wsparcie frameworku COCO.
- **Framework COCO (cocoex):** Wykorzystany do obsługi benchmarku BBOB-BIObj, generowania instancji problemów oraz rejestrowania wyników eksperymentów.
- **Biblioteki algorytmiczne:**
 - **pycomocma:** Dla implementacji MO-CMA-ES.
 - **GPflowOpt** lub **SMAC3** / **BoTorch:** Do implementacji wielokryterialnego algorytmu EGO (np. ParEGO).
- **Analiza danych:** Moduł **cocopp** do automatycznego generowania raportów porównawczych w formacie HTML i LaTeX oraz biblioteki **pandas** i **matplotlib** do własnych analiz statystycznych.